

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
”ВЫСШАЯ ШКОЛА ЭКОНОМИКИ”»

Московский институт электроники и математики

Юткин Дмитрий Игоревич, группа БИВ-141

**ПРИМЕНЕНИЕ ГЛУБОКИХ СВЁРТОЧНЫХ НЕЙРОННЫХ СЕТЕЙ ДЛЯ
РЕШЕНИЯ ЗАДАЧИ РАСПОЗНАВАНИЯ ОБРАЗОВ**

Междисциплинарная курсовая работа
по направлению 09.03.01.62 Информатика и вычислительная техника
студента образовательной программы бакалавриата
«Информатика и вычислительная техника»

Студент _____ Д.И. Юткин

Научный руководитель
Старший преподаватель
Д.В. Пантюхин

Москва 2016 г.

Аннотация

Работа посвящена решению задачи распознавания образов с использованием глубоких свёрточных нейронных сетей. В результате исследования было обучено несколько нейронных сетей различной глубины (от 9 до 18 слоёв), часть из которых обучалась на предварительно обработанных данных. Максимальная точность одиночной модели составила 93,4%, объединение нейронных сетей в ансамбль позволило увеличилась точность распознавания до 94,21%, что сравнимо с точностью человека. Все эксперименты проводились на наборе изображений CIFAR-10, с использованием графических процессоров и фреймворка для глубокого обучения Caffe.

Abstract

The research focused on application of deep convolutional neural networks for solving object recognition task in natural images. As a result, several models of different depth (from 9 to 18 layers) have been trained on preprocessed and augmented data. The best model has shown accuracy of 93,4% on a test images. Whereas, ensemble of combined models has achived 94,21% which is close-to-human performance. All experiments have been carried out on the CIFAR-10 dataset with modern GPUs and Caffe framework for a deep learning.

Оглавление

1 Введение	4
2 Основная часть	6
2.1 Датасет CIFAR-10	6
2.2 Фреймворк Caffe	7
2.3 Предварительная обработка данных	7
2.4 Обучение нейронных сетей	9
2.4.1 Модель I	9
2.4.2 Модели II и III	10
2.4.3 Модели IV и V	11
2.4.4 Модель VI	12
2.4.5 Модель VII	13
2.5 Объединение нейронных сетей в ансамбль	14
3 Заключение	16
Список литературы	17
Приложение	19

1 Введение

В последние годы компьютерное зрение является одной из самых активно развивающихся областей искусственного интеллекта. Подобный интерес к области обусловлен недавними успехами в обучении компьютера воспроизводить зрительные способности человека, например, распознавать и классифицировать образы.

До недавнего времени распознавание объектов осуществлялось с помощью алгоритмов, для которых вручную приходилось проектировать признаки (feature engineering). Основной недостаток такого подхода — невозможность находить в изображении средние и многоуровневые абстракции, такие как части объекта или пересечения различных краёв. Кроме того, признаки созданные вручную для одного типа изображений зачастую не были применимы к другим. Однако, недавние разработки в области машинного обучения, известные как глубокое обучение (deep learning) [1], показали, как вычислительные модели, состоящие из множества слоёв, могут автоматически изучать иерархии признаков из набора данных.

На сегодняшний день глубокое обучение развилось и укрепилось в отдельную ветвь машинного обучения, алгоритмы которой способствовали значительному улучшению результатов в различных задачах, таких как обработка естественного языка, распознавание визуальных образов и др.

Свёрточные нейронные сети (СНН) — одна из главных причин прорыва в компьютерном зрении. Изначально представленные в 1980 году Кунихикой Фукусимой как NeoCognitron [2], а затем улучшенные в 1998 году Яном Лекуном до LeNet-5 [3], СНН получили славу благодаря впечатляющему успеху в распознавании рукописных цифр. Для следующего прорыва в компьютерном зрении потребовалось чуть больше двадцати лет. С увеличением производительности графических процессоров (GPU), стало возможным обучение глубоких нейронных сетей. В 2012 году глубокая СНН победила в мировом соревновании ImageNet Large-scale Visual Recognition Challenge (ILSVRC), значительно превзойдя предыдущие результаты, достигнутые алгоритмами полагающимися на ручную генерацию признаков [4].

Таким образом, темой данного исследования является разработка системы распознавания объектов (object recognition), основанной на глубоких свёрточных нейронных сетях. Основные цели исследования:

- а) Изучение и применение на практике свёрточных нейронных сетей в решении задачи распознавания объектов;

- б) Изучение современных технологий машинного обучения, анализа данных и глубокого обучения.

Для достижения поставленных целей были сформулированы следующие задачи:

- а) Проведение обзора статей и литературы, посвящённых свёрточным нейронным сетям и решению задачи распознавания образов;
- б) Выбор и изучение программного обеспечения для глубокого обучения;
- в) Выбор набора данных, на котором будут проводиться эксперименты;
- г) Проектирование и обучение нейронных сетей различных архитектур;
- д) Оценка и сравнение точностей полученных нейронных сетей;
- е) Объединение отдельно обученных моделей в ансамбль.

Все поставленные задачи выполнены, цели исследования достигнуты. Результаты каждой из задач будут описаны далее, в основной части работы.

2 Основная часть

2.1 Датасет CIFAR-10

Набор данных, на котором проводились исследования, состоит из 60 000 цветных изображений, размера 32×32 пикселя. Каждое изображение принадлежит одному из 10 классов¹, что соответствует 6 000 изображениям на класс. Под обучение отводится 50 000 изображений. Остальные 10 000 используются для тестирования. Объекты в классах сильно варьируются, например, класс «птица» содержит различные виды птиц, как большие так и маленькие. Кроме того, объекты классов представлены в различных позах и под различными углами. Особенно это проявляется среди собак и кошек, которые изображены не только в различных позах, но иногда и частично, например, изображена только голова животного.

Датасет CIFAR-10 [5] был выбран для проведения исследований благодаря своему относительно небольшому размеру, который не только позволяет обучать глубокие нейронные сети используя GPU с памятью меньше 8 Gb, но и быстро проводить эксперименты и проверять на практике различные гипотезы.

На момент написания работы лучший результат (state-of-the-art) на CIFAR-10 96,53% [6]. Точность распознавания человека $\approx 94\%$.²




Рисунок 1 — 10 случайных изображений из каждого класса

¹самолёт, автомобиль, птица, кот, олень, собака, лягушка, лошадь, корабль, грузовик

²<http://karpathy.github.io/2011/04/27/manually-classifying-cifar10/>

2.2 Фреймворк Caffe

Свёрточные нейронные сети обучались с помощью фреймворка для глубокого обучения Caffe [7]. Изначально фреймворк разрабатывался командой BVLC (Berkeley Vision and Learning Center), но постепенно перерос в большой open-source проект.³ На данный момент вклад в развитие Caffe внесли почти 200 разработчиков и более 10 000 человек оценили проект на Github.

Данный фреймворк был выбран для решения задачи по нескольким причинам:

- а) Простота определения моделей и методов оптимизации. Архитектуры нейронных сетей (Caffe поддерживает топологии сетей в форме любых ациклических графов) и алгоритмы оптимизации удобно и эффективно определяются в специальных конфигурационных файлах типа Google Protocol Buffers⁴.
- б) Модульность. Caffe позволяет легко изменять архитектуру сети под новые форматы входных данных. Кроме того, в наличии имеется много слоёв и функций потерь.
- в) Скорость вычислений и эффективное использование ресурсов. Caffe заранее выделяет ровно столько памяти сколько нужно для нейронной сети. Операций линейной алгебры такие как умножение, сложение и свёртка выполняются на CPU с помощью BLAS (Basic Linear Algebra Subroutines). На GPU за эти операции отвечают библиотеки cuBLAS и cuDNN [8]
- г) CLI (command line interface) и интерфейсы для Python и Matlab.

Caffe написан на языках C++, Cuda, Python. Для хранения датасетов используются эффективные базы данных LMDB⁵ и LevelDB⁶. Обучение нейронных сетей может выполняться как на CPU, так и на нескольких GPU одновременно. Фреймворк доступен для Linux, Windows и OS X.

2.3 Предварительная обработка данных

Необработанные изображения содержат излишнюю информацию, так как смежные пиксели имеют высокую корреляцию. Поэтому прежде чем подавать

³<https://github.com/BVLC/caffe>

⁴<https://developers.google.com/protocol-buffers/>

⁵<http://symas.com/mdb/>

⁶<https://github.com/google/leveldb>

изображения на вход нейронной сети, они были обработаны в два этапа. В начале была произведена глобальная нормализация контраста (global contrast normalization) изображения:

$$\hat{X} = \frac{X - \bar{X}}{\sigma},$$

где X — исходное изображение, \bar{X} — среднее значение, σ — стандартное отклонение.

Затем изображения были линейно трансформированы с помощью алгоритма ZCA whitening [5]. Цель данного алгоритма сделать так, чтобы входные изображения слабо коррелировали друг с другом.

Алгоритм ZCA whitening:

```

1 cov = np.dot(X.T, X) / X.shape[0] # Вычисляем ковариационную матрицу
2 U,S,V = np.linalg.svd(cov) # Находим сигнулярное разложение ковариационной матрицы
3 Xrot = np.dot(X, U) # Поворачиваем входные данные
4 Xwhite = Xrot / np.sqrt(S + alpha) # Делим на собственные числа

```



Рисунок 2 — Изображения после применения ZCA whitening с параметром $\alpha = 0,1$

Предобработка с помощью ZCA whitening уменьшила ошибку в среднем на 1,5%. Кроме того, каждое изображение было увеличено до 40×40 пикселей, для того чтобы в процессе обучения вырезать из изображения случайный патч размером 32×32 . Такой приём позволяет снизить эффект переобучения модели и повысить конечную точность распознавания.

2.4 Обучение нейронных сетей

Во время исследования были проверены различные гипотезы, архитектуры и эвристики так или иначе влияющие на конечные точности моделей. В результате различных экспериментов были отобраны семь нейронных сетей, показавшие наилучший результат. Топологии этих сетей отражены в таблице 1, графики обучения на рисунке 17. Инициализация весов во всех моделях проводилась с помощью layer-sequential unit-variance (LSUV) [9]. Данный метод сначала проводит преинициализацию весов ортонормированными матрицами [10], затем, для каждого слоя настраивает параметры таким образом, чтобы дисперсия выходов была единичной. Далее будут описаны каждая из отобранных моделей, их свойства и особенности обучения.

2.4.1 Модель I

Модель I имеет самую низкую ошибку в предсказаниях среди всех обученных моделей (6,6%). СНН состоит из 18 обучающихся слоёв. Всего в нейронной сети $\approx 2,7$ млн. параметров.

Махout в качестве функции активации является её отличительной особенностью. На рисунке 3 показано как махout соединён с выходами свёрточных слоёв. На рисунке 4 можно видеть соединение выходов полносвязного слоя и активации.




Рисунок 3 — Соединение maxout'а со свёрточными слоями

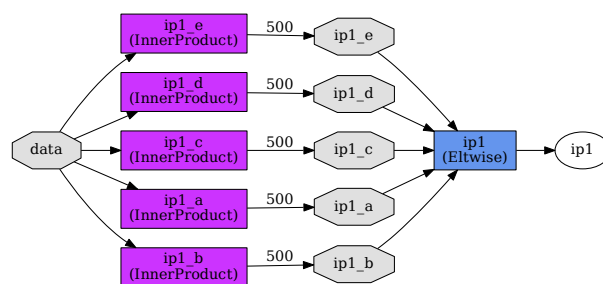


Рисунок 4 — Соединение maxout'а с полносвязными слоями

Нейронная сеть обучалась 90 000 итераций методом стохастического градиентного спуска, с начальным learning rate (lr) 0,01 и моментом 0.9. Кроме того, использовалась L2 регуляризация с коэффициентом 0,0005. В процессе обучения, начиная с 40 000 итерации, lr уменьшался в десять раз каждые 20 000 итераций.

Таким образом, к концу обучения lr достиг значения 10^{-5} . Mini batch состоял из 256 изображений.

	Plane	Car	Bird	Cat	Deer	Dog	Frog	Horse	Ship	Truck
Plane	943	4	13	9	1	0	2	1	16	11
Car	3	967	1	0	0	1	0	0	6	22
Bird	18	0	910	16	15	18	13	2	6	2
Cat	13	2	15	856	13	64	20	11	2	4
Deer	4	0	16	15	933	16	4	10	1	1
Dog	2	1	9	60	14	903	3	5	0	3
Frog	4	1	13	7	8	7	958	0	1	1
Horse	2	0	4	12	17	11	3	950	1	0
Ship	19	5	3	2	0	1	5	0	960	5
Truck	6	23	2	1	0	0	0	0	8	960

Рисунок 5 — Матрица предсказаний модели I

2.4.2 Модели II и III

Модель II имеет в 4,5 раза меньше параметров, в сравнении с моделью I. Их число составляет $\approx 600\,000$. Данная нейронная сеть имеет классическую архитектуру — чередование свёрточных и pooling слоёв, в качестве функции активации используется Leaky ReLU⁷ с параметром $\alpha = 0,01$.

Сеть обучалась в течении 30 000 итераций. Функционал ошибки оптимизировался алгоритмом Нестерова. Результат модели II оказался ниже на тестовом множестве, в сравнении с моделью I (89,4% против 93,4%). Данный результат объясняется недообучением, что является следствием недостаточного числа параметров нейронной сети. С другой стороны, за счёт уменьшения числа весов в модели, удалось снизить время обучения в 10 раз (с десяти часов до одного).

Модель III является попыткой исправить главный недостаток модели II за счёт увеличения числа параметров. В связи с чем, число фильтров каждого свёрточного слоя было увеличено в два раза, что позволило снизить ошибку на 1,6%.

⁷ $f(x) = \max(x, \alpha x)$

	Plane	Car	Bird	Cat	Deer	Dog	Frog	Horse	Ship	Truck
Plane	894	10	22	6	5	1	1	4	42	15
Car	3	956	2	0	1	1	1	0	8	28
Bird	21	1	856	27	36	20	22	10	5	2
Cat	10	3	36	738	38	109	29	20	10	7
Deer	4	0	24	14	910	12	13	20	1	2
Dog	7	3	25	78	20	840	7	17	0	3
Frog	6	2	16	19	12	4	937	1	1	2
Horse	5	1	8	6	25	26	1	923	2	3
Ship	21	7	3	3	2	0	4	1	948	11
Truck	8	33	1	2	0	0	2	0	8	946

Рисунок 6 — Матрица предсказаний модели II

	Plane	Car	Bird	Cat	Deer	Dog	Frog	Horse	Ship	Truck
Plane	913	4	21	6	6	1	2	3	31	13
Car	5	970	0	0	1	0	2	0	3	19
Bird	21	0	876	18	30	23	19	7	3	3
Cat	6	2	30	809	25	74	31	12	5	6
Deer	2	1	19	17	914	12	13	18	1	3
Dog	3	0	16	90	18	852	10	9	1	1
Frog	5	2	17	22	8	2	942	0	1	1
Horse	4	0	10	10	22	22	3	926	1	2
Ship	22	7	3	3	2	0	1	0	952	10
Truck	8	30	1	0	1	0	1	0	10	949

Рисунок 7 — Матрица предсказаний модели III

2.4.3 Модели IV и V

На моделях IV и V проверялась гипотеза, основная идея которой в том, что pooling слои могут быть заменены на соответствующие свёрточные слои с увеличенным параметром stride без значительного снижения точности распознавания. [11]. В данных сетях max-pooling 2×2 слои были заменены на свёрточные слои со stride равным двум.

Модель V имеет ≈ 6 млн. параметров и 13 слоёв. В качестве функции активации используется ReLU. После обучения в течении 14 часов и 50 000 итераций, точность на тестовом множестве достигла 92,1%, что подтверждает гипотезу о замене pooling слоёв.

Модель IV состоит из 16 слоёв и $\approx 7,8$ млн свободных параметров. Данная нейронная сеть является попыткой улучшить точность модели IV за счёт увеличения числа свёрточных слоёв. Однако, дополнительные слои привнесли дополнительно $\approx 1,8$ млн. параметров, что привело к переобучению и снижению конечной точности на 1,19%. Модель V обучалась в течении 50 000 итераций, что заняло 19 часов.

	Plane	Car	Bird	Cat	Deer	Dog	Frog	Horse	Ship	Truck
Plane	918	4	24	7	5	0	1	2	31	8
Car	5	960	0	2	1	1	1	0	6	24
Bird	17	0	888	20	23	19	15	9	5	4
Cat	9	1	24	824	24	76	18	15	6	3
Deer	2	0	9	17	935	16	5	10	4	2
Dog	0	0	14	63	15	891	2	14	0	1
Frog	7	1	17	22	4	1	942	1	4	1
Horse	5	0	7	4	17	16	1	947	1	2
Ship	21	6	2	4	1	0	2	0	957	7
Truck	8	25	1	3	0	1	3	0	10	949

Рисунок 8 — Матрица предсказаний модели IV

	Plane	Car	Bird	Cat	Deer	Dog	Frog	Horse	Ship	Truck
Plane	923	6	17	12	1	0	0	3	26	12
Car	3	967	1	2	0	2	0	0	4	21
Bird	17	0	885	31	19	26	8	11	3	0
Cat	6	1	19	845	15	80	13	12	5	4
Deer	4	0	26	30	889	17	7	24	2	1
Dog	3	2	19	97	10	850	2	17	0	0
Frog	8	2	26	44	10	11	896	0	2	1
Horse	6	0	10	14	7	14	1	948	0	0
Ship	25	5	3	7	0	1	1	0	950	8
Truck	7	35	1	6	0	0	2	2	8	939

Рисунок 9 — Матрица предсказаний модели V

2.4.4 Модель VI

Модель VI состоит из 18 слоёв и $\approx 4,2$ млн. параметров. Данная модель использует слои batch normalization, которые преобразовывают активаций свёрточных и полносвязных слоев таким образом, что их среднее равно нулю, а дисперсия единице (значения вычисляются на всём mini batch). Авторы batch normalization [12] утверждают, что данный приём позволяет использовать высокий learning rate и приводит к более быстрой сходимости. Модель VI достигла точности в 92,0% за 25 0000 итераций, а общее время затраченное на обучение (40 000 итераций) заняло 6 часов.




Рисунок 10 — Batch normalization слой в модели VI

	Plane	Car	Bird	Cat	Deer	Dog	Frog	Horse	Ship	Truck
Plane	931	2	16	9	3	1	2	3	19	14
Car	3	954	0	2	0	2	0	0	6	33
Bird	14	0	872	23	30	19	24	10	3	5
Cat	6	1	20	834	24	71	27	7	5	5
Deer	4	0	12	19	923	11	13	16	1	1
Dog	5	0	10	68	15	881	5	12	1	3
Frog	6	1	12	12	4	3	958	2	1	1
Horse	5	0	3	15	20	16	1	936	2	2
Ship	22	7	2	4	1	1	4	0	953	6
Truck	3	21	1	2	1	1	0	1	11	959

Рисунок 11 — Матрица предсказаний модели VI

2.4.5 Модель VII

Модель VII идентична модели I, за исключением количества свёрточных слоёв соединённых с тахout активацией. В данной модели их пять (Рис. 12), тогда как модель I имеет только два слоя. Такое изменение в топологии сети не привело к увеличению конечной точности модели, более того, ошибка увеличилась на 0,9%. Максимальное число итераций достигло 70 000, время затраченное на обучение составило 22 часа.

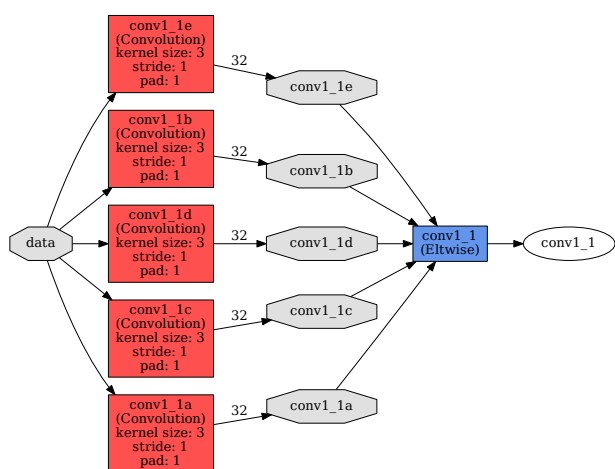


Рисунок 12 — Соединение тахout активаций в модели VII

	Plane	Car	Bird	Cat	Deer	Dog	Frog	Horse	Ship	Truck
Plane	939	5	9	10	3	0	4	1	21	8
Car	2	972	1	1	0	1	1	1	6	15
Bird	23	0	879	24	26	22	16	7	3	0
Cat	9	3	21	840	20	59	22	15	9	2
Deer	3	0	12	17	934	16	3	14	1	0
Dog	4	1	15	68	19	873	6	13	0	1
Frog	5	0	13	16	7	4	948	3	3	1
Horse	4	0	4	15	16	14	3	942	1	1
Ship	19	6	1	3	1	1	4	1	959	5
Truck	6	25	2	2	0	0	3	0	11	951

Рисунок 13 — Матрица предсказаний модели VII

2.5 Объединение нейронных сетей в ансамбль

Объединение нескольких моделей в ансамбль является мощным приёмом при решении различных задач машинного обучения. Применение подобной техники было выбрано по причине наличия различных свёрточных нейронных сетей, предсказания которых не очень сильно коррелируют между собой. В данном исследовании создание ансамбля производилось при помощи «стэкинга» (stacking) [13], идея которого заключается в построении алгоритма, объединяющего предсказания базовых моделей (в данном случае нейронных сетей). Такой подход зачастую работает лучше, так как усиливает обобщающую способность и робастность конечного классификатора за счёт одиночных моделей.

Для построения конечного ансамбля были протестированы различные алгоритмы классификации, такие как случайный лес, метод k ближайших соседей, машина опорных векторов и Extra Trees. Наилучшая точность была достигнута с помощью Extra Trees [14] (94,21%). Схема объединения моделей отражена на рисунке 14.

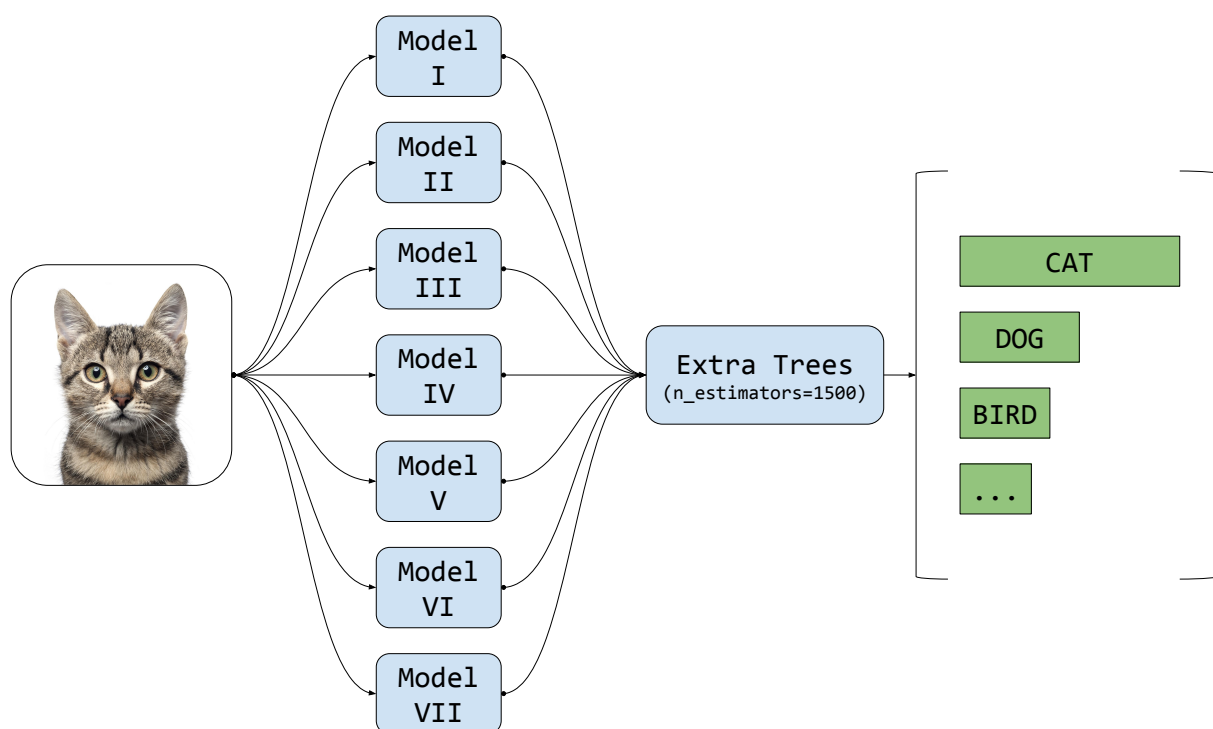


Рисунок 14 — Схема конечного ансамбля

	Plane	Car	Bird	Cat	Deer	Dog	Frog	Horse	Ship	Truck
Plane	956	3	6	9	1	0	2	1	14	8
Car	2	978	0	0	0	0	0	0	3	17
Bird	16	0	908	18	20	16	11	7	3	1
Cat	8	2	15	879	14	48	22	7	3	2
Deer	2	0	11	13	950	9	4	11	0	0
Dog	4	0	10	57	12	906	3	7	0	1
Frog	4	1	10	10	5	2	965	1	1	1
Horse	5	0	2	11	14	14	2	950	1	1
Ship	18	6	1	5	0	0	2	0	964	4
Truck	4	19	1	2	0	0	0	0	9	965

Рисунок 15 — Матрица предсказаний ансамбля моделей

3 Заключение

В результате выполнения курсовой работы был спроектирован и обучен ансамбль моделей, состоящий из семи различных глубоких свёрточных нейронных сетей и решающий задачу распознавания образов на датасете CIFAR-10 с точностью, превосходящей точность распознавания человека.

В процессе исследования были получены теоретические знания в области машинного обучения, анализа данных и глубокого обучения. В частности, были подробно изучены свёрточные нейронные сети и фреймворк Caffe, позволяющий реализовывать модели и современные алгоритмы компьютерного зрения. Полученные знания послужат фундаментом для дальнейших исследований в области глубокого обучения. Таким образом, по результатам работы можно сказать, что все поставленные задачи выполнены.

Список литературы

1. *Sutskever Ilya*. A Brief Overview of Deep Learning. — 01.13.2015. <http://goo.gl/1QVVmo>.
2. *Fukushima Kunihiko*. Neocognitron: A self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position // *Biological Cybernetics*. — Vol. 36, no. 4. — Pp. 193–202.
3. Gradient-Based Learning Applied to Document Recognition / Y. LeCun, L. Bottou, Y. Bengio, P. Haffner // *Proceedings of the IEEE*. — 1998. — November. — Vol. 86, no. 11. — Pp. 2278–2324.
4. *Krizhevsky Alex, Sutskever Ilya, Hinton Geoffrey E*. ImageNet Classification with Deep Convolutional Neural Networks // *Advances in Neural Information Processing Systems 25* / Ed. by F. Pereira, C. J. C. Burges, L. Bottou, K. Q. Weinberger. — Curran Associates, Inc., 2012. — Pp. 1097–1105.
5. *Krizhevsky Alex*. Learning multiple layers of features from tiny images. — 2009.
6. *Graham B*. Fractional Max-Pooling // *ArXiv e-prints*. — 2014. — dec. <http://adsabs.harvard.edu/abs/2014arXiv1412.6071G>.
7. Caffe: Convolutional Architecture for Fast Feature Embedding / Yangqing Jia, Evan Shelhamer, Jeff Donahue et al. // *arXiv preprint arXiv:1408.5093*. — 2014.
8. cuDNN: Efficient Primitives for Deep Learning / Sharan Chetlur, Cliff Woolley, Philippe Vandermersch et al. // *CoRR*. — 2014. — Vol. abs/1410.0759. <http://arxiv.org/abs/1410.0759>.
9. *Mishkin Dmytro, Matas Jiri*. All you need is a good init // *CoRR*. — 2015. — Vol. abs/1511.06422. <http://arxiv.org/abs/1511.06422>.
10. *Saxe Andrew M., McClelland James L., Ganguli Surya*. Exact solutions to the non-linear dynamics of learning in deep linear neural networks // *CoRR*. — 2013. — Vol. abs/1312.6120. <http://arxiv.org/abs/1312.6120>.

11. Striving for Simplicity: The All Convolutional Net / Jost Tobias Springenberg, Alexey Dosovitskiy, Thomas Brox, Martin A. Riedmiller // *CoRR*. — 2014. — Vol. abs/1412.6806. <http://arxiv.org/abs/1412.6806>.
12. *Ioffe Sergey, Szegedy Christian*. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift // *CoRR*. — 2015. — Vol. abs/1502.03167. <http://arxiv.org/abs/1502.03167>.
13. *Wolpert David H*. Stacked Generalization // *Neural Networks*. — 1992. — Vol. 5. — Pp. 241–259.
14. *Geurts Pierre, Ernst Damien, Wehenkel Louis*. Extremely Randomized Trees // *Mach. Learn.* — 2006. — apr. — Vol. 63, no. 1. — Pp. 3–42. <http://dx.doi.org/10.1007/s10994-006-6226-1>.

Приложение

Model I	Model II	Model III	Model IV	Model V	Model VI	Model VII
conv1_1 3x3x32	conv1_1 3x3x32	conv1_1 3x3x64	conv1_1 3x3x96	conv1_1 3x3x96	conv1_1 3x3x64	conv1_1 3x3x32
conv1_2 3x3x32	conv1_2 3x3x32	conv1_2 3x3x64	conv1_2 3x3x96	conv1_2 3x3x96	conv1_2 3x3x64	conv1_2 3x3x32
conv1_3 3x3x32	conv1_3 3x3x32	conv1_3 3x3x64	conv1_3 3x3x96	conv1_3 3x3x96	conv1_3 3x3x64	conv1_3 3x3x32
conv1_4 3x3x48	pool 2x2	pool 2x2	conv1_4 3x3x96 stride 2	conv1_4 3x3x96	conv1_4 3x3x64	conv1_4 3x3x48
conv1_5 3x3x48	conv2_1 3x3x64	conv2_1 3x3x128	conv2_1 3x3x192	conv1_5 3x3x96 stride 2	conv1_5 3x3x64	conv1_5 3x3x48
pool 2x2	conv2_2 3x3x64	conv2_2 3x3x128	conv2_2 3x3x192	conv2_1 3x3x192	pool 2x2	pool 2x2
conv2_1 3x3x80	conv2_3 3x3x64	conv2_3 3x3x128	conv2_3 3x3x192	conv2_2 3x3x192	conv2_1 3x3x128	conv2_1 3x3x80
conv2_2 3x3x80	conv2_4 3x3x64	conv2_4 3x3x128	conv2_4 3x3x192 stride 2	conv2_3 3x3x192	conv2_2 3x3x128	conv2_2 3x3x80
conv2_3 3x3x80	pool 2x2	pool 2x2	conv3_1 3x3x384	conv2_4 3x3x192	conv2_3 3x3x128	conv2_3 3x3x80
conv2_4 3x3x80	conv3_1 3x3x128	conv3_1 3x3x256	conv3_2 3x3x384	conv2_5 3x3x192 stride 2	conv2_4 3x3x128	conv2_4 3x3x80
conv2_5 3x3x80	conv3_2 3x3x128	conv3_2 3x3x256	conv3_3 3x3x384	conv3_1 3x3x384	conv2_5 3x3x128	conv2_5 3x3x80
conv2_6 3x3x80	conv3_3 3x3x128	conv3_3 3x3x256	conv3_4 3x3x384 stride 2	conv3_2 3x3x384	conv2_6 3x3x128	conv2_6 3x3x80
pool 2x2	conv3_4 3x3x128	conv3_4 3x3x256	pool global max	conv3_3 3x3x384	pool 2x2	pool 2x2
conv3_1 3x3x128	pool global	pool 2x2	fc 500	conv3_4 3x3x384	conv3_1 3x3x256	conv3_1 3x3x128
conv3_2 3x3x128	fc 256	fc 256	softmax 10	conv3_5 3x3x384 stride 2	conv3_2 3x3x256	conv3_2 3x3x128
conv3_3 3x3x128	softmax 10	softmax 10		pool global max	conv3_3 3x3x256	conv3_3 3x3x128
conv3_4 3x3x128				fc 500	conv3_4 3x3x256	conv3_4 3x3x128
conv3_5 3x3x128				softmax 10	conv3_5 3x3x256	conv3_5 3x3x128
conv3_6 3x3x128					conv3_6 3x3x256	conv3_6 3x3x128
pool global max					pool global AVE	pool global AVE
fc 500					fc 512	fc 512
softmax 10					softmax 10	softmax 10

Таблица 1: Архитектуры обученных моделей

	Plane	Car	Bird	Cat	Deer	Dog	Frog	Horse	Ship	Truck	Total
Model I	94.3	96.7	91	85.6	93.3	90.3	95.8	95	96	96	93.4
Model II	89.4	95.6	85.6	73.8	91	84	93.7	92.3	94.8	94.6	89.48
Model III	91.3	97	87.6	80.9	91.4	85.2	94.2	92.6	95.2	94.9	91.03
Model IV	91.8	96	88.8	82.4	93.5	89.1	94.2	94.7	95.7	94.9	92.11
Model V	92.3	96.7	88.5	84.5	88.9	85	89.6	94.8	95	93.9	90.92
Model VI	93.1	95.4	87.2	83.4	92.3	88.1	95.8	93.6	95.3	95.9	92.01
Model VII	93.9	97.2	87.9	84	93.4	87.3	94.8	94.2	95.9	95.1	92.37
Ensemble	95.8	97.8	90.9	87.6	95	90.8	96.2	95	96.4	96.6	94.21

Рисунок 16 — Точности распознавания по различным классам




Рисунок 17 — Графики обучения моделей